Certificazione CCAF · Claude Certified Architect

Architettura agentica e orchestrazione

Dominio 1 · peso del 27% nell'esame

Il loop: Claude decide, il codice esegue

1

Prompt e strumenti

Il messaggio e le definizioni degli strumenti.

2

Claude risponde

Sceglie uno strumento oppure risponde con testo.

3

Il codice esegue

Esegue lo strumento richiesto.

4

tool_result, poi ripeti

Il risultato torna a Claude, con lo stesso tool_use_id.

Il loop continua finché Claude non termina. Ma il codice decide l'uscita guardando stop_reason, non il testo.

stop_reason decide cosa fare

Valore	Azione
tool_use	Esegui lo strumento, restituisci il risultato, continua
end_turn	Claude ha terminato: mostra la risposta finale
pause_turn	Il loop lato server ha raggiunto il limite: invia di nuovo
max_tokens	Risposta troncata: valuta una continuazione
refusal	Il loop termina: esamina stop_details

Tre errori da evitare

Testo come segnale

"Se Claude scrive ho finito, esci dal loop."

Contatore come criterio

"Massimo cinque cicli, poi fermati." Va bene come protezione, non come criterio principale.

Testo uguale a fine

"Se c'è testo, ha terminato." Una risposta può contenere testo e un tool_use insieme.

Regola: il loop termina su stop_reason.

Hub-and-spoke: il coordinatore instrada tutto



I subagenti non comunicano mai direttamente tra loro: tutto passa dal coordinatore.

Il coordinatore: scompone, delega, aggrega

- Scompone l'attività in sottoattività
- Delega ai subagenti giusti
- Instrada ogni comunicazione
- Aggrega i risultati
- Rilancia il lavoro se trova lacune

Attenzione: scomposizione troppo ristretta

Obiettivo: ricerca sulle "industrie creative". Sottoattività: solo arti visive.

Mancano musica, scrittura, cinema e design. Serve una scomposizione più ampia e controlli di copertura.

Subagenti: il contesto non si eredita

Prompt vago

"Analizza il problema del cliente"

Il subagente non sa chi sia il cliente.

Prompt completo

Cliente 12345, ordine 67890, 149,99 euro, arrivato danneggiato. Richiede rimborso completo.

Per il parallelismo, il coordinatore invia più chiamate Agent nella stessa risposta.

Subagente nuovo o fork?

Aspetto	Subagente nuovo	Fork
Cronologia	Non ereditata	Ereditata per intero
Cache del prompt	Fredda	Condivisa con il padre
Usalo per	Attività circoscritte	Rami divergenti da una base comune

In entrambi i casi torna solo il risultato finale nella conversazione principale.

Istruzione o controllo programmatico?

Nel prompt

"Verifica sempre l'identità prima del rimborso."

Probabilistico: il rischio di errore non è nullo.

Hook PreToolUse

Blocca process_refund finché get_customer non ha verificato il cliente.

Deterministico: applicazione al 100%.

Regola: conseguenze finanziarie o di sicurezza = hook.

Hook: dove intervenire nel loop

Evento	Quando si attiva
PreToolUse	Prima dell'esecuzione: codice 2 o deny blocca
PostToolUse	Sul risultato: normalizza o rimuove dati sensibili
PostToolUseFailure	Quando lo strumento fallisce: retry e diagnostica
Stop / SubagentStop	Fine del turno o del subagente

Scomporre: sequenza fissa o adattiva?

Concatenazione

Passaggi noti in anticipo: l'output di uno alimenta il successivo.

Adattiva

Le sottoattività emergono dalle scoperte di ogni passaggio.

Revisione di una PR grande: un passaggio analizza ogni file da solo; un secondo passaggio, separato, controlla le interazioni tra file.

Sessioni: riprendere, ripartire, ramificare

--resume

Quando i risultati degli strumenti sono ancora validi.

Nuova sessione

Con un riepilogo strutturato, se i file sono cambiati.

--fork-session

Due strategie partendo dalla stessa base.

Dopo modifiche ai file, dillo esplicitamente a Claude: la sessione ripresa non se ne accorge da sola.

Da ricordare

1. Il loop termina su stop_reason, non sul testo.
2. Il contesto dei subagenti va passato esplicitamente.
3. Subagenti in parallelo: più chiamate Agent nella stessa risposta.
4. Conseguenze finanziarie o di sicurezza: hook, non prompt.
5. I subagenti non comunicano tra loro: passa tutto dal coordinatore.