Certificazione CCAF · Claude Certified Architect

Prompt engineering e output strutturato

Dominio 4 · peso del 20% nell'esame

Criteri espliciti

Elemento	Cosa scrivi nel prompt
Cosa rientra	Le condizioni precise che attivano la segnalazione
Cosa resta escluso	I casi limite che non devono attivarla
Esempi di confine	Coppie concrete: una segnalata, una no, con il perché

Una categoria rumorosa erode la fiducia in tutte le altre. Disattivala, migliora i criteri, riattivala.

Few-shot: 2 o 4 esempi mirati

Quando usarli

Scenari ambigui, formato da mostrare, casi limite, estrazione con allucinazioni.

Come scriverli

Input, output e ragionamento. Il ragionamento permette al modello di generalizzare invece di copiare.

Tre modi per l'output strutturato

Soluzione	Come	Nota
tool_use con schema	Strumento con input_schema e tool_choice forzato	Non su Fable 5.1 e Opus 5.5
strict	"strict": true, additionalProperties: false, tutto in required	Conformità allo schema
output_config.format	type: json_schema nell'output	Sostituisce output_format

Conformità non è correttezza

Lo schema garantisce

Tipi, campi obbligatori, valori enum.

Lo schema non garantisce

Il totale 150 con voci che sommano 175: JSON valido, dato sbagliato. Serve convalida nel codice.

Progettare lo schema

Pattern	Quando usarlo
["string", "null"]	Il dato può essere assente dal documento
Enum con "other"	Casi previsti in parte: aggiungi un campo di dettaglio
Enum con "unclear"	L'informazione può essere ambigua: il modello non deve indovinare

Ciclo di convalida e nuovo tentativo

Genera, convalida, aggiungi gli errori specifici al prompt, riprova con un massimo di tentativi.

Funziona

Errori di forma o di tipo: un campo mancante, una data malformata.

Non funziona

L'informazione non è nel documento: riprovare non la fa comparire. Accetta null.

Batch API

Usa il Batch	Usa il sincrono
Analisi notturna, report settimanali	Revisione prima del merge, passaggi CI bloccanti
Costo -50%, fino a 24 ore, senza SLA	Risposta in tempo reale
Risultati correlati con custom_id	Conversazioni con più turni

Revisione in più passaggi

Passaggio 1

Ogni file analizzato separatamente, con la stessa attenzione.

Passaggio 2

Interazioni tra file, con i risultati del primo come contesto.

Per PR di almeno 10 file, in una sessione indipendente da quella che ha scritto il codice.

Parametri dei modelli recenti

Vecchio approccio	Sui modelli recenti
budget_tokens, temperature, top_p	Errore 400. Thinking adaptive, profondità con output_config.effort
Prefill dell'assistente	Errore 400. Usa output_config.format
effort al livello principale	Va dentro output_config

Cache dei prompt: prefisso stabile

Ordine di rendering: tools, poi system, poi messages. Qualsiasi modifica nel prefisso invalida ciò che segue.

Stabile prima: system fisso, strumenti in ordine deterministico. Variabile dopo: timestamp, ID, domanda.

Riepilogo del dominio 4

1. Criteri espliciti: cosa rientra, cosa no, esempi di confine.
2. Lo schema garantisce la forma: la correttezza va verificata nel codice.
3. Dati assenti: null, non nuovo tentativo.
4. Batch per il non urgente, con custom_id come chiave.
5. Revisione in sessione indipendente, in più passaggi per PR grandi.
6. Prefisso stabile per la cache.