Certificazione CCAF · Claude Certified Architect

Contesto e affidabilità

Dominio 5 · peso del 15% nell'esame

Una finestra grande non è gratuita

Aspetto	Conseguenza
1M di token di finestra	Ogni token si paga a ogni turno e la qualità cala con la lunghezza
Nuovo tokenizer (4.7 in poi)	Circa il 30% di token in più: ricalibra con messages.count_tokens

La sintesi perde i numeri

Il riepilogo scrive

$149.99 diventa «circa $150». 2024-01-15 diventa «metà gennaio».

Il blocco dei fatti

ID cliente, numero d'ordine, date, importi, richiesta. Persistente, non riassunto.

Il problema del mezzo

I modelli leggono bene l'inizio e la fine di un input lungo. Il centro viene trascurato.

Mitigazione	Come
Riepilogo all'inizio	Risultati principali prima degli input aggregati
Intestazioni di sezione	Struttura di navigazione esplicita
Ripetizione ai bordi	Informazioni critiche sia in apertura sia in chiusura

Quando fare un'escalation

Sì

Il cliente chiede un operatore. Una lacuna nelle policy. Nessun progresso dopo tentativi ragionevoli.

No

Tono acceso o maiuscole. Bassa affidabilità dichiarata dal modello. Conversazione lunga.

Emozione non equivale a complessità: «SONO FURIOSO» per un addebito di $5 si risolve; un tono calmo su una questione di policy può richiedere un'escalation.

Errori: vuoto non è fallimento

Situazione	Stato	Risposta dell'agente
Ricerca valida, nessun risultato	200 + array vuoto	«Non ho trovato articoli»
Servizio inattivo	503 o timeout	«Non riesco a cercare ora»

Un errore strutturato dice cosa è successo e se è riprovabile: tipo, servizio, query, risultati parziali, retry_after_ms.

Codebase ampie e sessioni lunghe

Nelle sessioni lunghe Claude fa supposizioni, dimentica le scoperte e inizia a generalizzare invece di verificare.

Appunti e subagenti

Scratchpad che sopravvive alla compressione. Il subagente Explore legge 50 file e restituisce un riassunto.

Compattazione e manifesto

/compact proattivo con riepilogo strutturato. Un manifesto dello stato per riprendere dopo un arresto.

Revisione umana: misurare dove sbaglia

Tipo	Campione	Motivo
Rischio alto	20%	Errori più costosi
Rischio medio	10%	Revisione a campione
Rischio basso	5%	Controllo di regressione

Confidenza per campo, calibrata su un set etichettato: 0.9 deve voler dire corretto circa il 90% delle volte.

Provenienza delle informazioni

Conflitti

Annota il disaccordo con la fonte di ciascun valore. Mai scegliere in silenzio.

Date

data_as_of, source_published, retrieved_on: due valori di mesi diversi non sono una contraddizione.

Gestione del contesto lato server

Meccanismo	Cosa fa	Stato
Modifica del contesto	Elimina vecchi risultati o thinking	Eliminato
Compattazione	Riassume la conversazione	Blocco firmato
Strumento di memoria	File persistenti letti e scritti da Claude	Fuori dalla conversazione

Trappole della compattazione

Passa l'intero response.content, non solo il testo: estrarre il testo distrugge lo stato di compattazione senza errori.

Blocco compaction per primo nella richiesta successiva, senza i messaggi che riassume.

Limiti e rifiuti

Meccanismo	Quando usarlo
max_tokens	Limite invisibile: tronca a metà del lavoro
Budget dell'attività	Limite visibile al modello, per regolare il ritmo (non su Sonnet 5)
stop_reason: refusal	HTTP 200 con contenuto vuoto: va gestito esplicitamente

Riepilogo del dominio 5

1. Fatti critici in un blocco persistente, non lasciati alla sintesi.
2. Il sentiment non determina l'escalation: la complessità sì.
3. Un errore distingue «nessun risultato» da «ricerca non eseguita».
4. Accuratezza per tipo di documento e per campo; confidenza calibrata.
5. Conflitti annotati, date esplicite, nessuna fusione di fonti.
6. Compattazione lato server: intero response.content.